

机器学习入门文档

Introduction to Machine Learning: Concepts and Algorithms

作者：周教授

学校编号：SC002 | 专业大类：人工智能

第一章 机器学习概述

1.1 什么是机器学习

机器学习 (Machine Learning) 是人工智能的一个分支，研究如何让计算机通过数据自动改进性能，而无需进行明确的编程。Tom Mitchell给出的经典定义：如果一个计算机程序在某类任务T上的性能P，随着经验E的积累而提高，则称该程序从经验E中学习了任务T。

机器学习主要类型：

- 监督学习 (Supervised Learning)：从标记数据中学习映射函数，包括分类和回归任务
- 无监督学习 (Unsupervised Learning)：从未标记数据中发现隐藏结构，包括聚类和降维
- 强化学习 (Reinforcement Learning)：通过与环境交互学习最优策略

1.2 机器学习应用

机器学习已广泛应用于各个领域：

- 计算机视觉：图像分类、目标检测、人脸识别
- 自然语言处理：机器翻译、情感分析、问答系统
- 推荐系统：商品推荐、内容推荐、好友推荐

医疗健康：疾病诊断、药物发现、基因组分析 - 金融风控：信用评分、欺诈检测、量化交易

第二章 监督学习基础

2.1 线性回归

线性回归是最基础的回归算法，假设目标变量与特征之间存在线性关系。

模型表达式： $h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n$

其中 θ 为模型参数，通过最小化均方误差（MSE）来估计： $J(\theta) = (1/2m) * \sum (h_{\theta}(x^{(i)}) - y^{(i)})^2$

梯度下降更新规则： $\theta_j := \theta_j - \alpha * (\partial J / \partial \theta_j)$

2.2 逻辑回归

逻辑回归用于二分类问题，使用Sigmoid函数将线性输出映射到(0,1)概率区间。

Sigmoid函数： $\sigma(z) = 1 / (1 + e^{(-z)})$

决策边界：当 $\sigma(z) \geq 0.5$ 时，预测为类别1；否则预测为类别0。

损失函数（交叉熵）： $J(\theta) = -(1/m) * \sum [y^{(i)} \log(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)}))]$

2.3 支持向量机 (SVM)

SVM寻找最优超平面将不同类别的数据分开，最大化分类间隔（Margin）。

关键概念： - 支持向量：位于间隔边界上的样本点 -

核函数：将低维数据映射到高维空间，解决非线性分类问题 -

常用核函数：线性核、多项式核、RBF高斯核、Sigmoid核

第三章 决策树与集成学习

3.1 决策树

决策树通过递归划分特征空间实现分类或回归。常用算法包括ID3、C4.5和CART。

信息增益（ID3算法）： $\text{Gain}(D, A) = \text{Ent}(D) - \sum(|D_v|/|D|) * \text{Ent}(D_v)$

其中 $\text{Ent}(D)$ 为数据集D的信息熵： $\text{Ent}(D) = -\sum p_k * \log_2(p_k)$

3.2 随机森林

随机森林是Bagging集成方法的扩展，通过构建多棵决策树并投票得出最终结果。

算法特点：

- 样本随机：每棵树从训练集中有放回地随机采样
- 特征随机：每个节点分裂时随机选择部分特征
- 抗过拟合：通过平均降低方差，提高泛化能力

3.3 梯度提升树（GBDT）

GBDT采用串行训练方式，每棵新树拟合前面所有树的残差，逐步减小预测误差。

XGBoost和LightGBM是GBDT的高效实现，在数据竞赛中表现优异。

第四章 神经网络与深度学习

4.1 感知机与多层感知机

感知机是最简单的神经网络，包含输入层和输出层。多层感知机（MLP）增加隐藏层，可学习非线性映射。

前向传播： $z^l[l] = W^l[l]a^{l-1} + b^l[l]$ $a^l[l] = g(z^l[l])$

反向传播（链式法则）： $\partial L / \partial W^l[l] = \partial L / \partial a^l[l] * \partial a^l[l] / \partial z^l[l] * \partial z^l[l] / \partial W^l[l]$

4.2 卷积神经网络（CNN）

CNN专门处理具有网格结构的数据（如图像），通过卷积层、池化层和全连接层提取层次化特征。

核心组件： - 卷积层：使用滤波器提取局部特征 - 激活函数：ReLU、Leaky ReLU、ELU等 - 池化层：降维并增强平移不变性 - 批归一化：加速训练并提高稳定性

经典网络架构： - LeNet-5（1998）：5层，手写数字识别 - AlexNet（2012）：8层，ImageNet冠军 - VGGNet（2014）：16-19层，小卷积核堆叠 - ResNet（2015）：152+层，残差连接解决梯度消失

4.3 循环神经网络（RNN）

RNN处理序列数据，通过隐藏状态传递历史信息。变体包括LSTM和GRU，解决长期依赖问题。

LSTM门控机制： - 遗忘门：决定丢弃哪些历史信息 - 输入门：决定存储哪些新信息 - 输出门：决定输出哪些信息

第五章 模型评估与优化

5.1 评估指标

分类任务： - 准确率（Accuracy）：正确预测比例 - 精确率（Precision）：正例预测中真正例比例 - 召回率（Recall）：真正例中被正确预测比例 - F1分数：精确率和召回率的调和平均 - ROC曲线和AUC：不同阈值下的性能权衡

回归任务： - 均方误差（MSE） - 均方根误差（RMSE） - 平均绝对误差（MAE） - 决定系数（ R^2 ）

5.2 模型优化

- 交叉验证：K折交叉验证评估模型稳定性 - 超参数调优：网格搜索、随机搜索、贝叶斯优化 - 正则化：L1正则（Lasso）、L2正则（Ridge）、Dropout - 早停法（Early Stopping）：验证集性能不再提升时停止训练

本文档配套Python代码示例使用scikit-learn和TensorFlow框架实现，建议读者结合代码实践加深理解。